

APPLICATION MOBILE

Requête de l'utilisateur



Routeur local (règles simples, sans réseau)

Basculer vers le cloud seulement si :

- contexte > 1500 tokens (limite locale : 2048)
- raisonnement multi-étapes (maths, logique formelle)
- connaissances récentes (postérieures à l'entraînement)
- préférence pour la vitesse ET appareil connecté

par défaut



TRAITEMENT LOCAL

- Llama 3.2 1B Q4_K_M (llama.cpp)
- Questions factuelles, résumé, classification de sentiment
- Hors ligne, données sur l'appareil
- Mesuré (S26 Ultra) : ~3,1 s (~2,0 s hors rechargement du modèle)



par exception

TRAITEMENT CLOUD

(si connecté)

- API cloud (ex. Gemini 2.0 Flash)
- Raisonnement complexe, documents longs
- API mesurée (S26) : 0,29 s (warm)
- Données envoyées à un serveur